Annotation Guideline
Aspek Ulasan Aplikasi E-commerce

Kelompok HHH | Dani Setiawan (240712771), Isidorus Ambar Wicaksono (240712775), Johannes Calvin (240712781)

Mata kuliah Pemrosesan Bahasa Alami (versi 2.1: revisi setelah masukan dosen dan hasil IAA overlap)

1. Tujuan dan Ruang Lingkup

Dataset: ulasan pengguna aplikasi e-commerce (mis. Blibli) di Google Play Store (Dataset No. 8), target minimal 800 teks unik setelah cleaning. Ada dua skema anotasi yang **memakai satu set label yang sama** (6 label aspek, lihat Bagian 2):

• **Skema A (Multilabel Text Classification, document level):** memberi satu atau lebih label aspek pada satu ulasan.

• **Skema B (NER / Span Classification, token level):** menandai span teks yang menjadi bukti (evidence) dari aspek tersebut, dengan label span yang sama persis dengan label Skema A.

Sentimen (positif/negatif) **tidak** dianotasi. Label hanya menyatakan *aspek apa yang dibicarakan*, sehingga contoh positif dan negatif sama-sama sah untuk label yang sama.

2. Daftar Label (berlaku untuk Skema A dan Skema B)

Nama label, definisi, dan contoh dirancang selaras: setiap contoh membahas hal yang disebut dalam definisi. Pada contoh, **[teks dalam kurung siku]** adalah span yang ditandai pada Skema B.

Label	Definisi	Contoh (A: label dokumen; B: span)
PENGIRIMAN	Kecepatan/ketepatan waktu pengiriman, kurir, ekspedisi, kondisi atau keamanan kemasan paket saat diterima.	"Barangnya [cepat sampai] di rumah dan [kurirnya] ramah banget." "Paket datang [penyok] dan [telat 5 hari]." "Pesanan [sampai lebih cepat] dari estimasi."
LAYANAN_PELANGGAN	Respon dan penanganan Customer Service, seller, atau proses refund dan retur.	"[CS] sangat lambat merespons waktu saya mau [ajukan retur] barang rusak." "[Refund] cepat dan CS-nya membantu." "[Seller] tidak membalas [komplain] saya."
APLIKASI_PERFORMA	Kestabilan teknis aplikasi: error, bug, loading lambat, force close, nge-lag.	"Aplikasi sering [keluar sendiri] pas mau bayar." "Sekarang jauh lebih ringan, tidak ada lagi [loading lama]." "Setiap update malah jadi [error] dan [nge-lag]."
USABILITY	Mudah atau sulitnya memakai aplikasi: navigasi, tampilan antarmuka, pencarian, menemukan/memakai fitur.	"[Tampilannya] simpel dan [fitur pencariannya] gampang dipakai." "[Menu pesanan] susah banget dicari." "[Navigasinya] membingungkan."
PEMBAYARAN	Proses transaksi dan checkout: metode pembayaran, gagal bayar, saldo/refund dana masuk ke metode bayar, kendala pembayaran.	"[Pembayaran via e-wallet] sering [gagal] padahal saldo cukup." "[Checkout] lancar, [metode bayarnya] lengkap." "[Virtual account] tidak bisa dipakai."
PROMO_HARGA	Diskon, voucher, gratis ongkir, cashback, atau perbandingan harga.	"Banyak [promo diskon] dan [gratis ongkir] yang bikin hemat." "[Harganya] lebih mahal dari toko sebelah." "Dapat [voucher] 20 ribu pas pembelian pertama."

2.1 Aturan Inklusi, Eksklusi, dan Contoh Negatif

Contoh negatif adalah ulasan yang **tidak** diberi label tersebut walau terlihat mirip.

Label	Inklusi (label diberikan jika)	Eksklusi (label tidak diberikan jika)	Contoh negatif
PENGIRIMAN	Ulasan membahas waktu/proses kirim, kurir, ekspedisi, atau kondisi paket.	Hanya membahas kualitas/isi barang atau kesesuaian produk.	"Barangnya bagus dan sesuai foto." (bukan PENGIRIMAN)
LAYANAN_PELANGGAN	Ulasan membahas respon/penanganan CS, seller, refund, atau retur.	Hanya membahas fitur chat sebagai tampilan, atau kualitas barang tanpa interaksi layanan.	"Fitur chat-nya gampang ditemukan." (USABILITY)
APLIKASI_PERFORMA	Ulasan menyebut gangguan teknis: error, bug, lambat, force close, lag.	Keluhan tampilan/navigasi tanpa gangguan teknis.	"Tampilannya jadul." (USABILITY)
USABILITY	Ulasan menilai kemudahan memakai aplikasi, tampilan, navigasi, pencarian.	Keluhan kegagalan teknis (crash, lambat).	"Aplikasi sering crash." (APLIKASI_PERFORMA)
PEMBAYARAN	Ulasan membahas proses bayar/checkout, metode bayar, kegagalan transaksi.	Hanya membahas harga atau promo tanpa proses pembayaran.	"Harganya terlalu mahal." (PROMO_HARGA)
PROMO_HARGA	Ulasan membahas diskon, voucher, gratis ongkir, cashback, atau harga.	Hanya membahas proses bayar atau kualitas barang.	"Bayar pakai OVO gagal terus." (PEMBAYARAN)

Tidak ada label NETRAL, UMUM, atau TIDAK_JELAS. Ulasan yang tidak dapat diberi satupun dari enam label di atas **dibuang (di-ignore di Prodigy)** dan tidak dimasukkan ke dataset anotasi.

3. Panduan Skema A (Multilabel, Document Level)

• Baca seluruh ulasan, lalu centang **semua** label yang aspeknya dibahas secara eksplisit. Minimal satu, tidak ada batas maksimal.

• Label diberikan berdasarkan topik yang dibahas, bukan nada ulasan. Memuji dan mengeluh sama-sama memunculkan label aspek tersebut.

• Jangan menebak aspek yang tidak disebut. Hanya label yang punya bukti di dalam teks yang boleh dicentang.

• Jika tidak ada satupun label yang cocok, pilih **Ignore** di Prodigy (ulasan tidak masuk dataset).

4. Panduan Skema B (NER / Span Classification)

Label span = label Skema A. Sorot hanya bagian teks yang menjadi bukti aspek tersebut, lalu beri label aspeknya.

4.1 Apa yang harus di-highlight

Label	Yang di-highlight	Yang tidak di-highlight
PENGIRIMAN	Frasa kecepatan/keterlambatan, kurir/ekspedisi, kondisi paket: [cepat sampai], [kurirnya], [kemasan rusak], [JNE]	Kata sapaan, nama toko, kata sambung

Label	Yang di-highlight	Yang tidak di-highlight
LAYANAN_PELANGGAN	Pihak layanan (CS, seller, admin) dan aktivitas layanan: [CS], [ajukan retur], [refund], [komplain]	Kata kerja umum tanpa makna layanan ("minta", "bilang")
APLIKASI_PERFORMA	Gejala teknis: [force close], [error], [loading lama], [lag], [bug]	Kata "aplikasi" sendirian
USABILITY	Bagian antarmuka/fitur beserta penilaian kemudahannya: [tampilannya simpel], [susah dicari], [fitur pencarian]	Penilaian umum tanpa objek ("bagus")
PEMBAYARAN	Metode dan kendala bayar: [metode pembayaran], [gagal bayar], [checkout], [e-wallet]	Nama bank/dompet digital bila tidak terkait proses bayar
PROMO_HARGA	Penawaran dan harga: [gratis ongkir], [cashback 50%], [voucher], [harga mahal]	Kata "murah" yang menilai barang tanpa konteks harga di aplikasi

4.2 Aturan Batas Span

• Tandai frasa inti secara utuh. "gratis ongkir" ditandai sebagai satu span PROMO_HARGA, bukan hanya "ongkir".

• Tidak menyertakan tanda baca atau kata penghubung di tepi span, kecuali melekat secara tata bahasa.

• Kata dalam satu entitas tidak boleh dipotong jika pemotongan menghilangkan makna.

• Entitas multi-kata yang membentuk satu unit makna ditandai sebagai satu span.

• Posisi awal dan akhir span harus bisa diverifikasi terhadap teks asli (tanpa mengubah teks).

• Satu span = satu label. Span berlabel berbeda **boleh** tumpang tindih hanya jika frasa yang sama memang menjadi bukti dua aspek (mis. "pengiriman gratis" = PENGIRIMAN dan PROMO_HARGA); selain itu pilih span terpanjang yang bermakna jelas.

• Span **tidak** memuat tanda baca atau emoji di tepi, dan tidak memuat pujian umum ("bagus", "mantap", "love it"). Mulai dari kata inti aspek dan akhiri di kata inti terakhir ("sering error", bukan "Aplikasinya sering error,").

• Teks di luar span tidak diberi label (tag O).

• **Skema tag BIO:** token pertama span diberi B-LABEL, token lanjutannya I-LABEL, token lain O. Contoh "Gratis ongkir banyak banget": Gratis=B-PROMO_HARGA, ongkir=I-PROMO_HARGA, banyak=O, banget=O.

• Tokenisasi mengikuti spasi dan tanda baca; hasil BIO dibuat otomatis dari offset karakter span (start, end) di teks asli.

4.3 Hubungan Skema A dan B

Setiap label yang dicentang di Skema A sebaiknya didukung minimal satu span berlabel sama di Skema B, dan setiap span di Skema B harus punya label yang sama di Skema A pada ulasan itu. Contoh: ulasan "CS lambat, aplikasinya juga sering force close" -> A: LAYANAN_PELANGGAN, APLIKASI_PERFORMA; B: [CS lambat] = LAYANAN_PELANGGAN, [force close] = APLIKASI_PERFORMA.

5. Aturan Kasus Ambigu

5.1 Skema A (dokumen)

Kasus	Aturan	Contoh dan hasil
Sarkasme	Beri label aspek yang menjadi inti keluhan; abaikan nada sindiran karena sentimen tidak dianotasi.	"Hebat ya aplikasinya loading mulu seharian" -> APLIKASI_PERFORMA
Beberapa aspek / sentimen campuran	Centang semua aspek yang dibahas.	"Kurir cepat tapi aplikasinya sering error" -> PENGIRIMAN + APLIKASI_PERFORMA
Aspek tersirat	Label hanya jika aspek bisa disimpulkan dari kata yang tertulis; jangan menebak.	"Saldo kepotong tapi pesanan gagal" -> PEMBAYARAN
Aspek tumpang tindih (refund)	Refund/retur sebagai proses layanan = LAYANAN_PELANGGAN; dana tidak masuk ke metode bayar = tambah PEMBAYARAN.	"Refund ke e-wallet belum masuk 2 minggu" -> LAYANAN_PELANGGAN + PEMBAYARAN
Ongkir	Gratis ongkir/diskon ongkir = PROMO_HARGA. Keluhan ongkir yang mahal = PROMO_HARGA (aspek harga). Keluhan ongkir yang gagal diterapkan saat bayar = PROMO_HARGA + PEMBAYARAN.	"Gratis ongkirnya banyak" -> PROMO_HARGA
APLIKASI_PERFORMA vs USABILITY	Kata *mudah, gampang, simple, tampilan, menu, fitur, user friendly* = USABILITY. Kata *lancar, ringan, lemot, error, bug, crash, loading, tidak bisa dibuka* = APLIKASI_PERFORMA. Kata "aplikasi" saja bukan bukti APLIKASI_PERFORMA.	"Aplikasinya mudah dan lancar" -> USABILITY + APLIKASI_PERFORMA; "Aplikasi bagus" -> tidak diberi label itu
Kata "cepat" / "lama"	Konteksnya menentukan: cepat sampai = PENGIRIMAN; cepat respon CS/seller/refund = LAYANAN_PELANGGAN; cepat loading/pencarian = APLIKASI_PERFORMA; cepat proses bayar = PEMBAYARAN.	"Refund lama" -> LAYANAN_PELANGGAN; "Proses pembayaran cepat" -> PEMBAYARAN
Fitur chat dengan penjual	Saran/keluhan tentang **adanya fitur** chat = USABILITY. Keluhan tentang CS/seller yang lambat membalas = LAYANAN_PELANGGAN.	"Tambahkan menu chat dgn toko" -> USABILITY
Cicilan, kartu kredit, saldo dompet	Metode/proses cicilan, kartu kredit, top up, saldo = PEMBAYARAN. Ditambah PROMO_HARGA hanya bila ditekankan sebagai promo (cicilan 0%, cashback).	"Bisa cicilan pake BCA klikpay" -> PEMBAYARAN
Kemasan / packing	Kondisi dan kualitas kemasan = PENGIRIMAN. Kualitas atau keaslian isi barang di luar 6 aspek.	"Packingnya rapi" -> PENGIRIMAN; "Barang ori" -> tidak dilabeli
Pertanyaan atau saran fitur	Tetap dilabeli menurut **topik** yang disebut, bukan nadanya. Hanya doa/harapan umum tanpa aspek yang di-Ignore.	"Gimana cara bayarnya?" -> PEMBAYARAN; "Mudahan selalu lancar" -> Ignore
Ignore terlalu dini	Ulasan pendek yang jelas menyebut aspek (refund, gosend, harga) **tidak boleh** di-Ignore. Ignore hanya bila tak satupun dari 6 aspek disebut.	"Seneng belanja, pake gosend pagi siang sampai" -> PENGIRIMAN

Kasus	Aturan	Contoh dan hasil
Ulasan terlalu umum	Tanpa aspek spesifik, ulasan **dibuang** (Ignore). Tidak ada label netral/umum.	"Bagus sih", "Mantap", "Ok" -> Ignore
Ulasan di luar topik / spam	Dibuang (Ignore).	"Jual follower murah, DM ya" -> Ignore

5.2 Skema B (span)

Kasus	Aturan	Contoh dan hasil
Singkatan / slang	Tetap disorot dan diberi label aspek yang sesuai jika konteks jelas.	"[CS] lama" -> LAYANAN_PELANGGAN; "[apk] lemot": [lemot] -> APLIKASI_PERFORMA
Repetisi	Setiap kemunculan yang berfungsi sebagai bukti dianotasi.	"[error] terus, [error] lagi" -> dua span APLIKASI_PERFORMA
Span tidak jelas	Jika kata bermakna ganda dan konteks tidak cukup menentukan aspeknya, jangan dianotasi.	"Ribet" tanpa objek -> tidak ditandai
Satu frasa dua aspek	Pilih satu label yang paling mewakili inti frasa; pecah frasa jika memuat dua bukti terpisah.	"[pembayaran gagal]" tidak boleh dipecah menjadi "[pembayaran]" dan "[gagal]"; tandai satu span = PEMBAYARAN
Overlap	Dua label hanya boleh tumpang tindih bila frasa yang sama memang bukti dua aspek; selain itu pakai satu span terpanjang yang bermakna jelas.	"[pengiriman gratis]" = PROMO_HARGA dan PENGIRIMAN (boleh); "[gratis] [ongkir]" dipecah (tidak boleh)
Span tanpa pasangan di Skema A	Jika sebuah span tidak punya label setara di Skema A, tinjau ulang kedua skema sebelum menyimpan.	Span [kurir] ada, tetapi PENGIRIMAN tidak dicentang -> centang PENGIRIMAN
Teks di luar taksonomi	Tidak diberi label (tag O).	"Aplikasi ini saya download kemarin" -> tidak ada span

6. Contoh Anotasi Lengkap (Skema A + B)

Ulasan	Skema A	Skema B (span = label)
Barangnya cepat sampai dan kurirnya ramah banget.	PENGIRIMAN	[cepat sampai] = PENGIRIMAN; [kurirnya ramah] = PENGIRIMAN
Hebat ya aplikasinya loading mulu seharian, CS juga lama balas.	APLIKASI_PERFORMA, LAYANAN_PELANGGAN	[loading mulu] = APLIKASI_PERFORMA; [CS juga lama balas] = LAYANAN_PELANGGAN
Banyak promo diskon dan gratis ongkir, tapi pembayaran e-wallet sering gagal.	PROMO_HARGA, PEMBAYARAN	[promo diskon] = PROMO_HARGA; [gratis ongkir] = PROMO_HARGA; [pembayaran e-wallet sering gagal] = PEMBAYARAN
Tampilannya simpel, cari barang gampang.	USABILITY	[Tampilannya simpel] = USABILITY; [cari barang gampang] = USABILITY
Mantap.	(Ignore, tidak masuk dataset)	-

7. Prosedur dan Kualitas

• Anotasi dilakukan di Prodigy (anotasi.uajy.ac.id); tiap anggota menganotasi secara independen.

• Perbedaan antar anotator diselesaikan lewat adjudication; hasil IRR (Inter Rater Reliability) dari Prodigy dilaporkan.

• Cleaning data (data kosong, duplikat, spam, emoji/simbol saja, encoding rusak, markup) dilakukan sebelum anotasi.

• Ulasan yang di-Ignore dicatat jumlahnya dan dilaporkan di laporan.

8. Format Penyimpanan (JSONL)

Setiap baris dataset anotasi memuat teks, label multilabel (Skema A), dan daftar span (Skema B) dengan offset karakter:


```
{"text": "Kurir cepat tapi aplikasinya sering error", "labels": ["PENGIRIMAN", "APLIKASI_PERFORMA"], "entities": [{"text": "Kurir cepat", "start": 0, "end": 11, "label": "PENGIRIMAN"}, {"text": "sering error", "start": 29, "end": 41, "label": "APLIKASI_PERFORMA"}]}
```


Catatan: taxonomy ini diajukan ke dosen untuk disetujui; setelah disetujui, taxonomy dibekukan (freeze) dan perubahan substansial harus disertai alasan, catatan versi, dan persetujuan dosen. Label OUT_OF_SCOPE tidak dipakai; ulasan yang tidak bisa dilabeli di-Ignore sesuai arahan dosen.

9. Riwayat Revisi dan Bukti Agreement

Overlap annotation 200 ulasan oleh tiga annotator menghasilkan Fleiss' kappa rata-rata 0,65 (PENGIRIMAN 0,81; PROMO_HARGA 0,75; LAYANAN_PELANGGAN 0,69; USABILITY 0,67; PEMBAYARAN 0,55; APLIKASI_PERFORMA 0,46). F1 span dengan batas persis hanya sekitar 0,30, dan 41 dari 200 ulasan tidak disepakati status Ignore-nya. Perubahan v2.1 berikut diturunkan dari temuan tersebut:

• Menambahkan aturan pembeda APLIKASI_PERFORMA vs USABILITY dan konteks kata "cepat/lama" (label dengan kappa terendah).

• Menegaskan batas span (tanpa tanda baca di tepi, tanpa pujian umum) dan mengizinkan overlap antarlabel secara terbatas.

• Menegaskan aturan Ignore: label diberikan menurut topik; pertanyaan atau saran yang menyebut aspek tetap dilabeli. Ini **mengoreksi** arahan awal yang menyarankan pertanyaan di-Ignore.

• Menambahkan aturan fitur chat, cicilan/saldo, dan kemasan.

• Adjudication: label diputuskan lewat suara mayoritas (minimal 2 dari 3 annotator), lalu ditinjau berdasarkan guideline; 36 dari 200 ulasan diputuskan manual (31 berlabel dan 5 Ignore; lihat KelpHHH_adjudication_log.csv).

Taxonomy 6 label tidak berubah (dibekukan); yang direvisi hanya aturan penerapan.