Laporan UTS
Dataset Development: Multilabel Aspek dan NER Ulasan Aplikasi E-commerce

Mata kuliah Pemrosesan Bahasa Alami | Gasal 2026/2027 | Kelompok HHH

Dani Setiawan (240712771), Isidorus Ambar Wicaksono (240712775), Johannes Calvin (240712781)

1. Pemilihan Dataset dan Perumusan Masalah

Kelompok memakai Dataset No. 8, Indonesian Google Play Review untuk aplikasi e-commerce (ulasan aplikasi Blibli). Dataset asli berisi 10.040 ulasan (train + validation digabung) dengan kolom text, label (sentimen pos/neg), dan stars (1-5). Label sentimen asli tidak dipakai sebagai taxonomy; ia hanya dipakai sebagai referensi awal untuk menjaga proporsi pos/neg pada pemilihan sampel.

Ulasan pengguna aplikasi e-commerce jarang membahas satu hal saja. Satu ulasan sering memuat pujian pada pengiriman sekaligus keluhan pada aplikasi atau pembayaran. Karena itu perumusan masalah dibuat menjadi dua tugas yang saling berkaitan pada label yang sama:

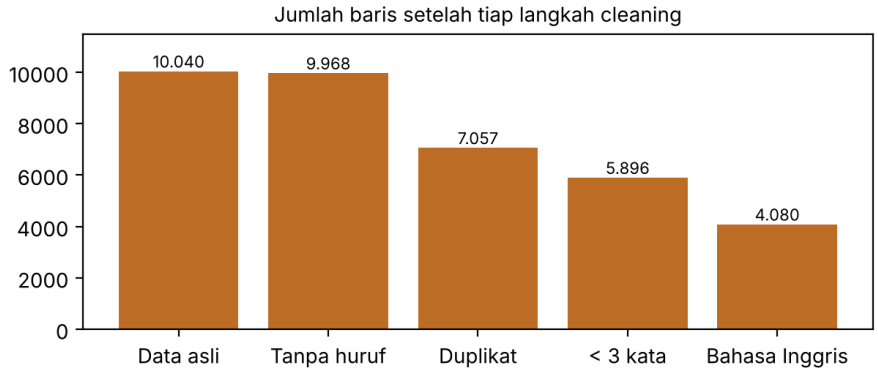
- Multilabel text classification (level dokumen): menentukan aspek apa saja yang dibicarakan dalam satu ulasan.
- NER / span extraction (level token): menandai frasa bukti (evidence) bagi tiap aspek tersebut.

Kegunaannya: tim produk dapat mengetahui aspek mana yang paling banyak dikeluhkan beserta kutipan buktinya, tanpa membaca ribuan ulasan satu per satu. Sentimen sengaja tidak dianotasi; label hanya menyatakan aspek yang dibahas, sehingga pujian dan keluhan pada aspek yang sama diperlakukan sebagai label yang sama.

2. Data Cleaning

Cleaning dilakukan di notebook KelpHHH_dataset_EDA.ipynb dan dapat dijalankan ulang dari awal. Normalisasi hanya mengubah whitespace (baris baru dan spasi ganda), tidak mengubah huruf, ejaan, atau tanda baca, sehingga offset span NER tetap valid terhadap teks. Kolom text_raw dan id menjaga penelusuran ke data asli.

Langkah	Alasan	Dibuang	Tersisa
Normalisasi whitespace	Baris baru acak tidak bermakna	0	10.040
Buang teks tanpa huruf	Emoji/simbol/angka saja tidak dapat dianotasi	72	9.968
Buang markup/URL/encoding rusak	Noise teknis (diperiksa; tidak ditemukan)	0	9.968
Deduplikasi (huruf kecil, tanda baca diabaikan)	Setiap teks akhir harus unik	2.911	7.057
Buang teks kurang dari 3 kata	Terlalu pendek memuat aspek	1.161	5.896
Buang teks Inggris murni (heuristik)	Target bahasa Indonesia	1.816	4.080



Gambar 1. Jumlah baris setelah tiap langkah cleaning.

Hasilnya 4.080 teks bersih dan unik (target minimal 800 terpenuhi). Deteksi bahasa memakai heuristik kata penanda sehingga sebagian kecil teks campuran bisa salah buang atau lolos; kesalahan semacam ini ditangani lewat aturan Ignore saat anotasi.

Pemilihan sampel anotasi. Sebagian besar ulasan hanya berisi pujian umum ("bagus", "mantap"). Untuk mendapatkan data yang kaya aspek, dipilih 1.000 ulasan dari 2.601 ulasan yang mengandung minimal satu kata penanda aspek (leksikon sederhana per label), dengan proporsi pos/neg asli terjaga (668 pos, 332 neg). Leksikon hanya dipakai untuk memilih sampel dan bukan sebagai label; label diberikan manual oleh annotator. Sampel ini membuat distribusi label lebih kaya daripada populasi, sehingga kesimpulan prevalensi label tidak boleh digeneralisasi ke seluruh ulasan.

3. Taxonomy Multilabel dan NER

Taxonomy dirancang dari pola yang muncul pada corpus dan dibekukan setelah disetujui dosen. Skema A (dokumen) dan Skema B (span) memakai satu set enam label yang sama, sesuai masukan dosen:

Label	Cakupan
PENGIRIMAN	Kecepatan/ketepatan kirim, kurir, ekspedisi, kondisi kemasan
LAYANAN_PELANGGAN	Respon dan penanganan CS/seller, refund, retur, komplain
APLIKASI_PERFORMA	Kestabilan teknis: error, bug, lemot, force close, loading
USABILITY	Kemudahan memakai aplikasi: tampilan, navigasi, pencarian, fitur
PEMBAYARAN	Proses bayar/checkout, metode bayar, cicilan, saldo, kegagalan transaksi
PROMO_HARGA	Diskon, voucher, gratis ongkir, cashback, harga

Satu teks dapat memiliki lebih dari satu label, dan label dapat muncul bersama secara wajar (misalnya PROMO_HARGA dan PENGIRIMAN lewat frasa "gratis ongkir"). Tidak ada label NETRAL atau UMUM; ulasan yang tidak membahas satu pun aspek di-Ignore dan tidak masuk dataset. Skema tag span memakai BIO (B-LABEL, I-LABEL, O) yang diturunkan dari offset karakter. Penyimpanan JSONL berisi text, labels, dan entities (start, end, label, text).

Guideline (KelpHHH_annotation_guideline.pdf, versi 2.1) memuat definisi, aturan inklusi/eksklusi, contoh positif dan negatif, aturan batas span, serta aturan untuk kasus ambigu (sarkasme, banyak aspek, refund yang tumpang tindih, ulasan terlalu umum, dan lainnya).

4. Proses Anotasi

Anotasi dilakukan di Prodigy (anotasi.uajy.ac.id) dengan tampilan Multi Tipe (Span): klasifikasi multilabel dan penandaan span pada tiap ulasan. Dari 1.000 ulasan, 200 dijadikan subset overlap yang dilabeli ketiga anggota secara independen (dipilih stratifikasi pos/neg), dan 800 sisanya dibagi tiga (sekitar 267 ulasan per anggota) sebagai anotasi individu.

Annotator	Overlap dilabeli	Overlap di-Ignore	Individu masuk dataset	Diubah dari draft
Dani Setiawan	200	0	265 dari 267	50 (19%)
Isidorus Ambar Wicaksono	180	20	264 dari 267	155 (58%)
Johannes Calvin	171	29	266 dari 266	21 (8%)

Kontribusi tiap anggota dapat ditelusuri dari ekspor Prodigy (_annotator_id). Pada bagian individu, draf label dan span awal dibuat dengan alat pra-anotasi berbasis aturan yang dibuat dengan bantuan AI generatif; setiap anggota meninjau dan memperbaiki draf miliknya di Prodigy sebelum dipakai sebagai gold. Kelompok bertanggung jawab penuh atas hasil akhirnya.

Dataset akhir (KelpHHH_dataset_annotation.jsonl) berisi 990 teks unik: 195 dari gold overlap hasil adjudication dan 795 dari anotasi individu (Dani 265, Isidorus 264, Johannes 266). Dari jatah individu masing-masing, Dani membuang 2 ulasan tanpa label, dan Isidorus meng-Ignore 2 ulasan serta menolak (reject) 1 ulasan. Kolom "Diubah dari draft" menunjukkan banyaknya ulasan yang label atau span-nya berbeda dari draf pra-anotasi; tingkat koreksi berbeda antaranggota (8% sampai 58%), sehingga kualitas bagian individu juga berbeda. Hal ini diakui sebagai keterbatasan.

Koreksi sistematis. Setelah penggabungan ditemukan bahwa alat pra-anotasi versi awal keliru menandai kata "lagi" (bermakna "again") sebagai APLIKASI_PERFORMA karena pola kata lag. Kesalahan ini terbawa pada 30 span di 26 ulasan (Dani 9, Isidorus 1, Johannes 20) karena draf diterima tanpa koreksi. Span tersebut dihapus secara otomatis, dan label APLIKASI_PERFORMA dihapus dari 23 ulasan yang tidak punya bukti lain; pola alat dikoreksi.

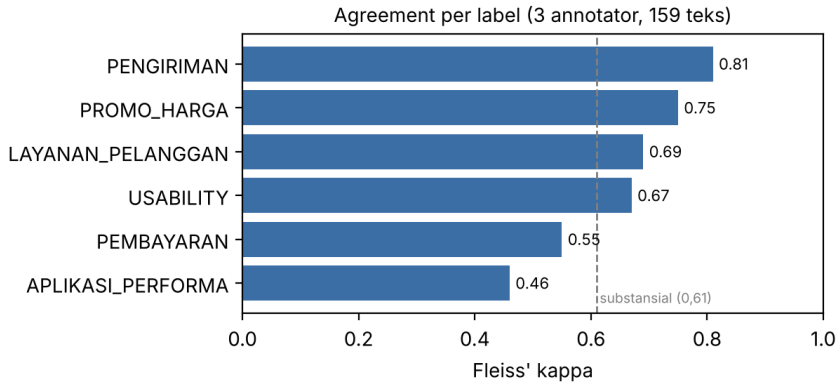
5. Inter-Annotator Agreement

Agreement dihitung pada 200 ulasan overlap. Karena beberapa ulasan di-Ignore oleh sebagian annotator, ada 159 ulasan yang dilabeli ketiganya (dasar perhitungan Fleiss) dan perhitungan pasangan memakai ulasan yang dilabeli kedua annotator.

5.1 Multilabel

Label	Fleiss' kappa	Interpretasi
PENGIRIMAN	0,81	hampir sempurna
PROMO_HARGA	0,75	substansial

LAYANAN_PELANGGAN	0,69	substansial
USABILITY	0,67	substansial
PEMBAYARAN	0,55	sedang
APLIKASI_PERFORMA	0,46	sedang
Rata-rata (macro)	0,65	substansial



Gambar 2. Fleiss' kappa per label.

Pasangan	n teks	Kappa rata-rata (6 label)	Kesamaan himpunan label
Dani - Isidorus	180	0,68	50%
Dani - Johannes	171	0,62	47%
Isidorus - Johannes	159	0,63	52%

Pada 159 ulasan yang dilabeli ketiganya, ketiga annotator memberi himpunan label yang persis sama hanya pada 36% ulasan, karena satu label berbeda saja sudah dianggap tidak sama. Kappa per label lebih informatif daripada angka ini.

5.2 Span (NER)

Pasangan	F1 batas persis	F1 tumpang tindih	Kappa token
Dani - Isidorus	0,31	0,51	0,39
Dani - Johannes	0,28	0,52	0,41
Isidorus - Johannes	0,30	0,50	0,45

Annotator sering menandai bagian teks yang sama dengan batas awal/akhir berbeda (F1 tumpang tindih sekitar 0,5 dibanding sekitar 0,3 untuk batas persis). Ini wajar untuk span berupa frasa dan menjadi dasar penegasan aturan batas span pada guideline v2.1.

5.3 Kesepakatan status Ignore

Dari 200 ulasan, 159 dilabeli ketiganya, 33 di-Ignore oleh satu annotator (Isidorus 12, Johannes 21), dan 8 di-Ignore oleh Isidorus dan Johannes bersamaan. Dani tidak pernah memakai Ignore. Jadi 41 ulasan (20,5%) tidak disepakati status Ignore-nya, yang menunjukkan aturan Ignore pada guideline awal belum cukup jelas.

Catatan tentang Prodigy: tombol Hitung IAA pada Prodigy mengembalikan percent_agreement = 1, kripp_alpha = 0, dan gwet_ac2 = 1 dengan n_categories = 1 (551 anotasi, 192 contoh beririsan, 8 contoh beranotasi tunggal). Hasil itu tidak informatif karena Prodigy hanya membandingkan status jawaban (semuanya accept), bukan label aspek atau span. Karena itu agreement bermakna pada laporan ini dihitung sendiri dari ekspor anotasi (skrip pada notebook/kode terlampir); output Prodigy dilampirkan sebagai bukti proses.

6. Analisis Disagreement dan Adjudication

Sumber utama disagreement yang ditemukan:

- Batas APLIKASI_PERFORMA vs USABILITY. Dani memberi APLIKASI_PERFORMA 42 kali, Isidorus 20, Johannes 61. Contoh: "Aplikasi belanja OL paling parah UI nya, mau transaksi aja repotnya luar binasa" diberi USABILITY oleh dua annotator dan APLIKASI_PERFORMA oleh satu.
- Kapan PEMBAYARAN ikut dicentang. Contoh refund yang dana belum kembali, atau pesanan dibatalkan setelah dibayar.
- Ulasan lintas aspek. Contoh: "cashback PLN kalah dengan Bukalapak" diberi PROMO_HARGA oleh dua annotator dan LAYANAN_PELANGGAN oleh satu.
- Gaya pelabelan. Rata-rata label per teks: Dani 1,73; Isidorus 1,46; Johannes 1,48. Dani cenderung longgar, Johannes lebih ketat pada status Ignore.

Metode adjudication: label dokumen diputuskan lewat suara mayoritas (minimal 2 dari 3 annotator), kemudian seluruh ulasan yang tidak disepakati ditinjau terhadap guideline. Dari 200 ulasan overlap, 58 disepakati bulat, 142 tidak bulat; 164 ulasan berlabel akhirnya diputuskan lewat mayoritas dan 31 lewat keputusan manual berdasarkan guideline, sedangkan 5 ulasan di-Ignore secara manual (total 36 keputusan manual; log lengkap pada KelpHHH_adjudication_log.csv). Span gold dipilih dari span annotator yang memuat label tersebut: klaster span yang tumpang tindih dengan dukungan terbanyak, diwakili span yang paling mirip dengan lainnya, dengan tanda baca di tepi dibuang; untuk 15 pasangan label-ulasan tanpa span dari annotator, span ditentukan manual.

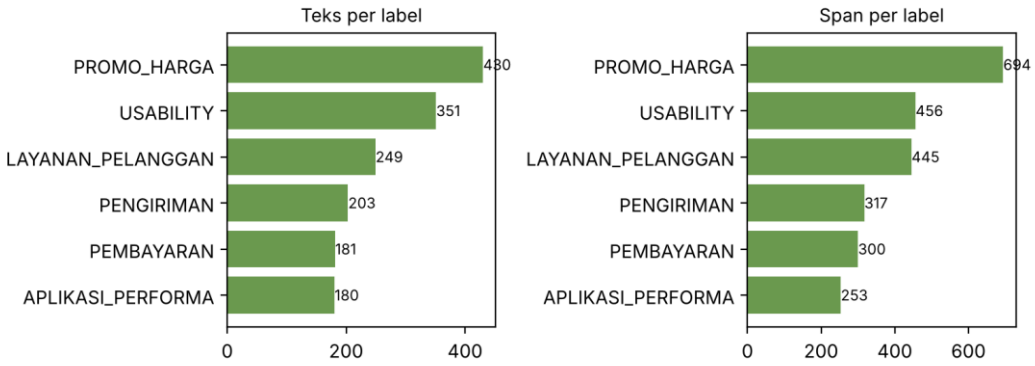
Contoh ulasan	Dani	Isidorus	Johannes	Keputusan
cashback PLN kalah dgn Bukalapak	PROMO_HARGA	LAYANAN_PELANGGAN	PROMO_HARGA	PROMO_HARGA (tidak menyebut CS)
Apps bagus, simple dan tampilan menarik	USABILITY	Ignore	USABILITY	USABILITY
Mudah, murah, hemat	PROMO, USABILITY	USABILITY	PROMO, USABILITY	PROMO_HARGA + USABILITY
mudahan selalu lancar	APLIKASI_PERFORMA	Ignore	Ignore	Ignore (doa umum, tanpa aspek)
barang mahal2! proses refund lama!	PEMBAYARAN, PROMO	LAYANAN	Ignore	PROMO_HARGA + LAYANAN_PELANGGAN

Perubahan guideline (v2.1) yang diturunkan dari temuan ini: aturan pembeda APLIKASI_PERFORMA vs USABILITY dan konteks kata "cepat/lama"; aturan fitur chat, cicilan/saldo, dan kemasan; penegasan batas span; serta aturan Ignore berbasis topik. Taxonomy 6 label tidak berubah. Satu koreksi arahan: pertanyaan yang menyebut aspek (mis. "gimana cara bayarnya?") tetap dilabeli menurut topik, sedangkan doa/harapan umum di-Ignore.

Agreement hanya dihitung pada subset overlap (200 ulasan) sebelum guideline direvisi. Setelah anotasi individu selesai, agreement tidak dihitung ulang karena bagian individu dilabeli satu annotator per ulasan, sehingga tidak ada pasangan annotator untuk dibandingkan. Sebagai gantinya, kualitas bagian individu dipantau lewat tingkat koreksi terhadap draf pra-anotasi (Bab 4) dan koreksi sistematis pada kata “lagi”. Seluruh anotasi individu dikerjakan dengan guideline v2.1, yaitu versi yang sudah memuat perbaikan dari hasil IAA overlap.

7. Exploratory Data Analysis

EDA lengkap (distribusi panjang teks, distribusi label, jumlah label per teks, kombinasi dan co-occurrence, korelasi antarlabel, imbalance, distribusi span, panjang span, dominasi tag O, dan span paling sering) ada di notebook dan otomatis memakai file anotasi final. Berikut ringkasan dari dataset akhir.



Gambar 3. Distribusi label dan span pada dataset akhir.

- Pada dataset akhir (990 teks) rata-rata 1.61 label dan 2.49 span per teks, sehingga masalah ini memang multilabel dan bukan single-label.
- Imbalance ratio label (maks/min) sekitar 2.4 dan span sekitar 2.7: tidak ekstrem, tetapi APLIKASI_PERFORMA dan PEMBAYARAN lebih jarang daripada PROMO_HARGA dan USABILITY. Pada UAS perlu metrik per label dan, bila perlu, pembobotan kelas.
- Sekitar 78% token bertag O (hanya sekitar 22% token berada dalam span), sehingga untuk NER metrik berbasis entity (F1 entity) lebih tepat daripada akurasi token.
- Karena label span sama dengan label dokumen, prediksi dokumen dapat diperiksa dengan bukti span-nya.

8. Dataset Explorer dan Reproducibility

Aplikasi KelpHHH_dataset_explorer.py (Streamlit) menyediakan lima halaman: Overview (ringkasan dan taxonomy), Browse Data (teks dengan label dan span ter-highlight), Multilabel Analysis (distribusi, kombinasi, co-occurrence, korelasi, imbalance), NER Analysis (distribusi span, span terbanyak, contoh ter-highlight), dan Filter/Search (pencarian teks serta filter label dan span). Jalankan dengan: streamlit run KelpHHH_dataset_explorer.py. Notebook dapat dijalankan ulang dari awal (Restart and Run All) dengan path relatif.

9. Keterbatasan dan Rencana UAS

- Sampel anotasi dipilih dari ulasan yang mengandung kata penanda aspek, sehingga tidak mewakili seluruh populasi ulasan.
- Kesepakatan span dan status Ignore masih menjadi titik lemah; guideline v2.1 menanganinya tetapi belum diukur ulang.
- Label APLIKASI_PERFORMA dan PEMBAYARAN lebih jarang dan kappa-nya lebih rendah, sehingga berisiko pada pemodelan multilabel.
- Target minimal 800 teks beranotasi terpenuhi (990). Rencana UAS: pembagian train/validation/test yang menjaga distribusi label, baseline multilabel (TF-IDF + klasifier) dan model berbasis IndoBERT, serta NER dengan evaluasi entity-level.

10. Penggunaan AI dan Kontribusi

Kelompok memakai AI generatif sebagai alat bantu untuk penyusunan skrip cleaning/EDA, analisis agreement, draf adjudication, draf guideline, aplikasi explorer, dan draf pra-anotasi. Seluruh keputusan label akhir, peninjauan hasil, dan isi laporan menjadi tanggung jawab kelompok.

Ketiga anggota berkontribusi pada seluruh tahap proyek, yaitu perancangan taxonomy dan penyusunan guideline, anotasi, adjudication, EDA, pengembangan dataset explorer, dan penulisan laporan. Pekerjaan dibahas bersama dan hasil akhir ditinjau oleh seluruh anggota.

Kontribusi pada anotasi dapat diverifikasi dari ekspor Prodigy (_annotator_id):

Anggota	Overlap dilabeli	Individu masuk dataset
Dani Setiawan	200	265
Isidorus Ambar Wicaksono	180	264
Johannes Calvin	171	266

Jumlah overlap yang berbeda terjadi karena sebagian ulasan di-Ignore oleh annotator yang menilainya tidak memuat aspek (Bab 4).